PROJETO – WEB CRAWLER, API E DASHBOARD DE DADOS

Você foi contratado para desenvolver uma pequena plataforma de coleta e análise de dados da Web.

O objetivo do projeto é criar um sistema capaz de acessar automaticamente um site público, coletar informações relevantes, armazená-las em um banco de dados MongoDB e disponibilizá-las por meio de uma API desenvolvida com FastAPI. Ao final, os dados deverão ser apresentados em um dashboard para facilitar sua visualização e análise.

DESAFIO

Escolha um site público que contenha informações estruturadas e que possam ser coletadas automaticamente.

Algumas possibilidades são: notícias, filmes e séries, livros, produtos, vagas de emprego, imóveis, jogos, resultados esportivos, restaurantes ou algum catálogo público.

O site escolhido deve permitir uma coleta adequada para fins educacionais. Não devem ser coletados dados pessoais, informações privadas ou conteúdos que não possam ser utilizados dessa forma.

A partir do site escolhido, desenvolva uma aplicação que realize todo o processo de coleta, armazenamento, disponibilização e visualização dos dados.

WEB CRAWLER

Desenvolva um Web Crawler em Python responsável por acessar as páginas do site escolhido e coletar os dados definidos pelo grupo.

O crawler deverá acessar as páginas automaticamente, identificar e extrair as informações relevantes, realizar um tratamento básico dos dados, evitar registros duplicados e armazenar a data e hora da coleta.

Os dados coletados deverão ser armazenados no MongoDB.

O crawler deverá funcionar de forma independente da API.

BANCO DE DADOS

Utilize MongoDB para armazenar os dados coletados.

A estrutura dos documentos deverá ser definida pelo grupo de acordo com o tipo de informação coletada.

Além dos dados extraídos do site, cada registro deverá possuir informações que permitam identificar quando e de onde o dado foi coletado.

O sistema deverá permitir novas coletas sem apagar os dados coletados anteriormente.

API

Desenvolva uma API utilizando FastAPI para disponibilizar os dados armazenados no MongoDB.

A API deverá possuir, no mínimo, endpoints para listar os registros, consultar um registro específico, realizar algum tipo de filtro ou busca e retornar informações estatísticas sobre os dados coletados.

A API também deverá disponibilizar os dados necessários para alimentar o dashboard.

DASHBOARD

Desenvolva um dashboard web para visualizar os dados coletados.

O dashboard deverá consumir os dados exclusivamente por meio da API desenvolvida com FastAPI.

O dashboard deverá apresentar a quantidade total de registros, pelo menos dois indicadores relevantes para o domínio escolhido, pelo menos dois gráficos, uma forma de filtrar ou pesquisar os dados e uma tabela ou listagem dos registros coletados.

Os gráficos deverão apresentar informações relevantes e permitir que o usuário compreenda melhor os dados coletados.

REQUISITOS TÉCNICOS

O projeto deverá utilizar Python no desenvolvimento do crawler e da API, FastAPI para a construção da API, MongoDB para persistência dos dados e uma tecnologia web para desenvolvimento do dashboard.

O projeto deverá ser organizado em módulos, separando pelo menos as responsabilidades de coleta, persistência, API e interface.

ENTREGA

O grupo deverá entregar o código-fonte completo do projeto, instruções para instalação e execução, documentação da estrutura do banco de dados, descrição do site escolhido e dos dados coletados, documentação dos endpoints da API e uma demonstração do sistema funcionando.

Durante a apresentação, o grupo deverá demonstrar o processo completo: execução do crawler, armazenamento dos dados no MongoDB, consulta dos dados pela API e visualização das informações no dashboard.

OBJETIVO FINAL

Ao final do projeto, deverá existir um sistema funcional no qual o fluxo completo seja:

Site → Web Crawler → MongoDB → FastAPI → Dashboard

O projeto será avaliado considerando o funcionamento do crawler, qualidade da coleta e tratamento dos dados, organização do banco de dados, implementação da API, qualidade do dashboard, integração entre os componentes e organização geral do código.